

Sprawozdanie z laboratorium:  
Uczenie Maszynowe i Sieci Neuronowe

1 lipca 2013

Prowadzący: dr hab. inż. Maciej Komosiński

Autorzy:	<b>Maciej Trojan</b>	inf94378	ISWD	maciek.trojan@me.com
	<b>Paweł Rychły</b>	inf94362	ISWD	pawelrychly@gmail.com

Zajęcia środowe, 11:45.

# 1 Uczenie nadzorowane sztucznych sieci neuronowych

**Zadanie 2.** Różnice funkcjonalne pomiędzy sieciami jedno- i wielowarstwowymi oraz pomiędzy sieciami liniowymi a nieliniowymi (uczenie sieci warstwowych funkcji logicznej AND i funkcji różnicy symetrycznej XOR)

1. Skonstruuj zbiór przykładów definiujący dwuargumentową funkcję ("bramkę") AND (File—New—Data set) i zachowaj go. Wszystkie 4 przykłady mają stanowić zbiór uczący. Jakie są klasy decyzyjne w tym zbiorze przykładów i jakie są ich licznosci?


Zbiór zawiera dwie klasy decyzyjne: 1 i 0. Ich licznosci wynoszą odpowiednio: 1 i 3.

VAR1	VAR2	decyzja
0	0	0
0	1	0
1	0	0
1	1	1

Tabela 1: Zbiór przykładów uczących


AND - Pożądana funkcja odpowiedzi.

+




Rysunek 1: Pożądana funkcja odpowiedzi sieci


3. Wyobraź sobie (narysuj) pożądaną funkcję odpowiedzi sieci (trójwymiarowy wykres zależności wyjścia od dwóch wejść)



Rysunek 2: Funkcja odpowiedzi sieci



Rysunek 3: Wykres błędu




Rysunek 4: Błędy dla poszczególnych przypadków

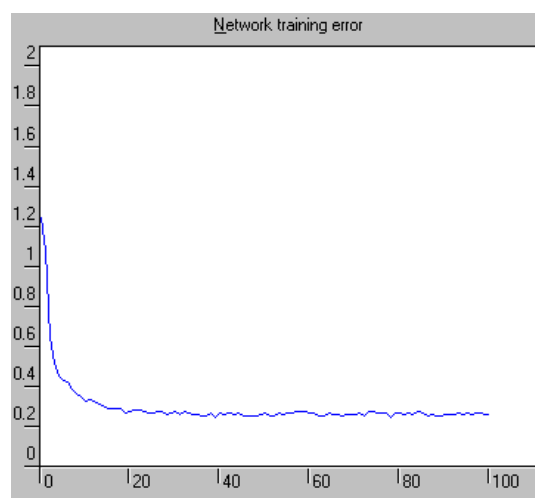
4. Skonstruuj liniową sieć jednowarstwową o architekturze 2-1 (File—New—Network, Type=Linear, przycisk Advise). Uaktywnij okno wykresu błędu średniokwadratowego (Statistics—Training graph). Naucz sieć na problemie AND (Train—Multilayer perceptron—Back propagation). Obejrzyj funkcję odpowiedzi sieci (Run—Response surface) i błędy dla poszczególnych przypadków (Statistics—Case errors)

5. Spróbuj utworzyć sieć liniową dla problemu AND o liczbie warstw większej niż 2.


Program Statistica uniemożliwia utworzenie takiej sieci.



Rysunek 5: Funkcja odpowiedzi sieci



Rysunek 6: Wykres błędu



Rysunek 7: Błędy dla poszczególnych przypadków

6. Przerób sieć na nieliniową sieć jednowarstwową (ustawiając Act fn w Edit—Network na Logistic) i naucz ją na tym samym problemie.


7. Wejść do edytora sieci (Network—Edit) i przypatrz się wagom neuronu wyjściowego. Wykreśl w przestrzeni wejść prostą, którą definiuje neuron wyjściowy i oceń, czy i jak realizuje ona separację klas decyzyjnych.

wagi:

$w_0 = 0.2847$

$w_1 = 0.5152$

$w_2 = 0.4980$



Rysunek 8: Prosta w przestrzeni wejść definiująca neuron wyjściowy


Prosta dokonuje niepoprawnej separacji klas decyzyjnych. Zgodnie z narysowaną prostą przypadki 0, 1 oraz 1, 0 należałyby do klasy 1.

VAR1	VAR2	decyzja
0	0	0
0	1	1
1	0	1
1	1	0

Tabela 2: Zbiór przykładów uczących


**8. Skonstruuj zbiór przykładów definiujący dwuargumentową funkcję XOR i zachowaj go. Wszystkie 4 przykłady mają stanowić zbiór uczący.**

XOR - Pożądana funkcja odpowiedzi.

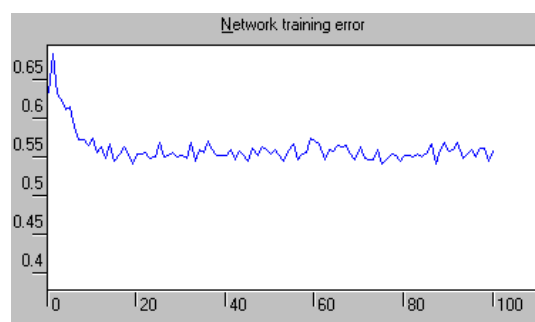


Rysunek 9: Pożądana funkcja odpowiedzi sieci


**9. Wyobraź sobie (narysuj) pożądaną funkcję odpowiedzi sieci.**



Rysunek 10: Funkcja odpowiedzi sieci




Rysunek 11: Wykres błędu




Rysunek 12: Błędy dla poszczególnych przypadków



10. Skonstruuj liniową sieć jednowarstwową o architekturze 2-1 i naucz ją na problemie XOR. Obejrzyj funkcję odpowiedzi sieci i błędy dla poszczególnych przypadków.



Rysunek 13: Funkcja odpowiedzi sieci




Rysunek 14: Wykres błędu



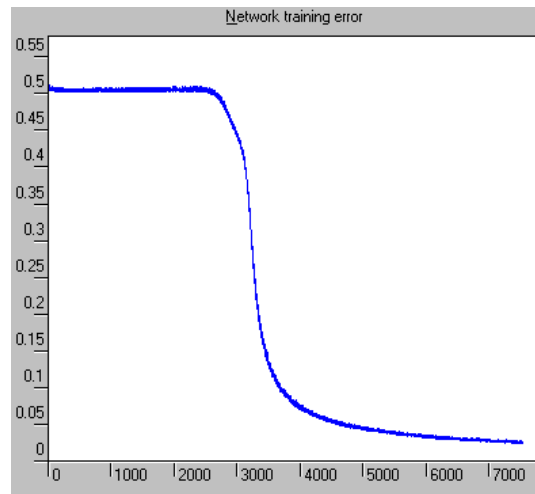
Rysunek 15: Błędy dla poszczególnych przypadków

11. Przerób sieć na nieliniową sieć jednowarstwową i naucz ją na tym samym problemie (zwróć uwagę, jak sieć stara się minimalizować błąd). Obejrzyj, jak zmienia się rozkład wag podczas procesu uczenia (Statistics—Weight distribution).


W trakcie procesu uczenia wartości wag zbiegały się do siebie.



Rysunek 16: Funkcja odpowiedzi sieci



Rysunek 17: Wykres błędu




Rysunek 18: Błędy dla poszczególnych przypadków

12. Skonstruuj nieliniową sieć dwuwarstwową o architekturze 2-2-1 (File—New—Network, Type=Multilayer perceptron) i naucz ją na problemie XOR. Obejrzyj funkcję odpowiedzi.

0	h1#01	h1#02
Th	-3.132	2.722
a1	-6.088	-5.279
a2	6.116	5.042

Tabela 3: Wagi neuronów w warstwie ukrytej



Rysunek 19: Proste wyznaczone przez neurony warstwy ukrytej


**13. Obejrzyj wagi sieci w edytorze sieci (Edit—Network). Jakie proste definiują neurony w warstwie ukrytej (spróbuj je narysować w przestrzeni wejść) ? Jak można interpretować działanie neuronu wyjściowego ?**

Neuron wyjściowy agreguje informacje pochodzące z neuronów ukrytych. Wagi neuronów warstw ukrytych definiują płaszczyzny w przestrzeni wejść. Neuron wyjściowy dokonuje klasyfikacji, w oparciu o te płaszczyzny.

**14. Obejrzyj, jak zmienia się rozkład wag podczas procesu uczenia. Jaka jest przyczyna takiego zachowania wag i jakie to może mieć konsekwencje (z "informatycznego" punktu widzenia) ?**

W trakcie uczenia sieci, wartości bezwzględne wag systematycznie rosną. Może to doprowadzić do przekroczenia zakresu liczb.

**Zadanie 3. Obserwacja zjawiska przeuczenia na przykładzie zbioru PIMA**



Rysunek 20: Dwuwarstwowa sieć neuronowa o architekturze 8-4-1.

**2. Wczytaj zbiór PIMA i skonstruuj dla niego dwuwarstwową sieć nieliniową o architekturze 8-4-1.**

Classification

Accept  Output type Confidence

Reject  Scale

Time Series Handling

Steps  Lookahead

Pre/Post Processing


Inputs  Input Fn None

Outputs  Output Fn None

	Convert	Missing	Min/Mean	Max/SD
ATR1	Minimax	Mean	0	1
ATR2	Minimax	Mean	0	1
ATR3	Minimax	Mean	0	1
ATR4	Minimax	Mean	0	1
ATR5	Minimax	Mean	0	1
ATR6	Minimax	Mean	0	1

Rysunek 21: Okno Pre/Post Processing

**3. Obejrzyj ustawienia w okienku Pre/Post Processing.**




Rysunek 22: Przebieg błędów dla zbioru uczącego i weryfikującego

**5. Przeprowadź uczenie algorytmem wstecznej propagacji błędów (może być bardzo długie, np. 20 000 epok); obserwuj przebieg błędów dla zbioru uczącego i weryfikującego.**

Jak można zauważyć na powyższym wykresie, po około 5000 epok błąd średniokwadratowy dla zbioru weryfikującego zaczął rosnąć. Spowodowane jest to efektem przeuczenia.

**Zadanie 4. Dobór liczby neuronów w warstwie ukrytej na przykładzie zbioru IRIS.**



Rysunek 23: Przebieg błędów uczenia w zależności od liczby neuronów w warstwie ukrytej

**3. Czy istnieje jednoznaczna zależność pomiędzy  $n$  a przebiegiem błędów średniokwadratowych? Czy biorąc pod uwagę tylko przebieg błędów dla zbioru uczącego można ustalić optymalną liczbę neuronów w warstwie ukrytej? Jeśli tak, to ile ona wynosi dla tego zbioru przykładów?** Jak można zauważyć na powyższym wykresie, większa liczba neuronów w warstwie ukrytej spowodowała, że błąd w początkowych

epokach uczenia spadał szybciej. Różnica ta malała jednak w kolejnych etapach. Nie można ustalić optymalnej liczby neuronów w warstwie ukrytej.